

Tarea 1

SP-1637 Análisis de sobrevivencia — IIC-2026

Gustavo Murillo

Mario Alvarado

11 de septiembre de 2026

Contenidos

Carga de datos	1
Ejercicio 1	2
Ejercicio 2	2
Ejercicio 3	2
Ejercicio 4	3
Ejercicio 5	3
Ejercicio 6	4
Ejercicio 7	5
Sexo	5
Educación	5
Religión	5
Zona	6
Ejercicio 8	6

Carga de datos

```
library(haven)
library(dplyr)
library(survival)
library(survminer)

# setwd("C:/Users/Mario.alvarado/OneDrive - Ministerio de Comercio Exterior/Aprendizaje/Estadistica/2

datos <- read_dta("encfec2010.dta") %>%
  filter(region == 8)

View(datos)

summary(datos)
table(datos$region)
```

Ejercicio 1

```
datos <- datos %>%
  mutate(
    r201b = na_if(r201b, 99),
    r201c = na_if(r201c, 9999),
    r216m = na_if(na_if(r216m, 98), 99),
    r216a = na_if(na_if(r216a, 9998), 9999),
    evento = case_when(
      r215 == 1 ~ 0,
      r215 %in% c(2, 3) ~ 1,
      TRUE ~ NA_real_
    ),
    tiempo_union = case_when(
      evento == 0 ~ as.numeric(r202),
      evento == 1 ~ ((r216a - r201c) * 12 + (r216m - r201b)) / 12,
      TRUE ~ NA_real_
    )
  )

summary(datos$r201b)
summary(datos$r216m)
table(datos$r215, datos$evento, useNA = "ifany")
summary(datos$tiempo_union)
```

Ejercicio 2

```
so.1 <- Surv(time = datos$tiempo_union, event = datos$evento)
fit1 <- survfit(so.1 ~ 1)

summary(fit1)$table
ggsurvplot(fit1, data = datos)
```

La mediana es de 24.24

La proporción de personas que nunca se unen es de 10.2%

Ejercicio 3

```
summary(fit1)
```

- La edad media de la primera unión es de 24.24
- Aproximadamente el 25 % de las personas de la región Pacífico Central había experimentado su primera unión conyugal al alcanzar los 19.83 años
- Cree una curva de hazards

```
tabla_hazard <- data.frame(
  Tiempo = fit1$time,
```

```

    Sobrevivientes = fit1$n.risk,
    Eventos = fit1$n.event
  ) %>%
  mutate(
    delta_t = Tiempo - lag(Tiempo),
    ht = (Eventos / Sobrevivientes) / delta_t
  ) %>%
  filter(is.finite(ht))

suavizam <- loess(ht ~ Tiempo, data = tabla_hazard)
suav <- predict(suavizam)

plot(
  suav ~ tabla_hazard$Tiempo,
  type = "l",
)

```

Ejercicio 4

```

datos <- datos %>%
  mutate(
    ednivel_cat = case_when(
      ednivel <= 10 ~ "Primaria o menos",
      ednivel <= 30 ~ "Secundaria",
      ednivel <= 50 ~ "Postsecundaria",
      TRUE ~ NA_character_
    )
  )

```

Ejercicio 5

```

datos <- datos %>%
  mutate(
    religion_cat = case_when(
      r209 == 1 ~ "Católica",
      r209 %in% c(2, 3, 4, 5, 7) ~ "Otra religión",
      r209 == 8 ~ "No creyente",
      TRUE ~ NA_character_
    ),
    sexo_cat = factor(
      r204,
      levels = c(1, 2),
      labels = c("Hombre", "Mujer")
    ),
    zona_cat = case_when(
      zona == 1 ~ "Urbana",
      zona == 2 ~ "Rural",
      TRUE ~ NA_character_
    )
  )

```

```
)
```

Ejercicio 6

```
fit.sexo <- survfit(so.1 ~ as.factor(sexo_cat), data = datos)
fit.educacion <- survfit(so.1 ~ as.factor(ednivel_cat), data = datos)
fit.religion <- survfit(so.1 ~ as.factor(religion_cat), data = datos)
fit.zona <- survfit(so.1 ~ as.factor(zona_cat), data = datos)
```

```
graf.sexo <- ggsurvplot(
  fit.sexo,
  data = datos,
  pval = TRUE,
  title = "Sexo",
  xlab = "Edad",
  ylab = "Probabilidad de permanecer sin unión"
)
```

```
graf.educacion <- ggsurvplot(
  fit.educacion,
  data = datos,
  pval = TRUE,
  title = "Educación",
  xlab = "Edad",
  ylab = "Probabilidad de permanecer sin unión"
)
```

```
graf.religion <- ggsurvplot(
  fit.religion,
  data = datos,
  pval = TRUE,
  title = "Religión",
  xlab = "Edad",
  ylab = "Probabilidad de permanecer sin unión"
)
```

```
graf.zona <- ggsurvplot(
  fit.zona,
  data = datos,
  pval = TRUE,
  title = "Zona",
  xlab = "Edad",
  ylab = "Probabilidad de permanecer sin unión"
)
```

```
arrange_ggsurvplots(
  list(
    graf.sexo,
    graf.educacion,
    graf.religion,
```

```

    graf.zona
  ),
  ncol = 2,
  nrow = 2,
  print = TRUE
)

```

Ejercicio 7

La función correcta es `survdif()`, con dos letras **f**. Para todas las pruebas se utiliza un nivel de significancia de $\alpha = 0.05$.

Sexo

```

prueba.sexo <- survdiff(so.1 ~ sexo_cat, data = datos)
prueba.sexo$pvalue

```

Hipótesis nula: $H_0 : S_{Hombre}(t) = S_{Mujer}(t) \Rightarrow h_{Hombre}(t) = h_{Mujer}(t)$.

Hipótesis alternativa: $H_1 : S_{Hombre}(t) \neq S_{Mujer}(t) \Rightarrow h_{Hombre}(t) \neq h_{Mujer}(t)$.

Interpretación: Como el p-value es 0.0084, menor que 0.05, se rechaza la hipótesis nula. Hay evidencia estadísticamente significativa de que las curvas de supervivencia de la edad a la primera unión son diferentes entre hombres y mujeres.

Educación

```

prueba.educacion <- survdiff(so.1 ~ ednivel_cat, data = datos)
prueba.educacion$pvalue

```

Hipótesis nula: $H_0 : S_{Primaria}(t) = S_{Secundaria}(t) = S_{Postsecundaria}(t) \Rightarrow h_{Primaria}(t) = h_{Secundaria}(t) = h_{Postsecundaria}(t)$.

Hipótesis alternativa: $H_1 : \text{al menos una } S_i(t) \neq S_j(t) \Rightarrow \text{al menos una } h_i(t) \neq h_j(t)$.

Interpretación: Como el p-value es 0.6947, mayor que 0.05, no se rechaza la hipótesis nula. No hay evidencia estadísticamente significativa de diferencias entre las curvas según el nivel educativo.

Religión

```

prueba.religion <- survdiff(so.1 ~ religion_cat, data = datos)
prueba.religion$pvalue

```

Hipótesis nula: $H_0 : S_{Catlica}(t) = S_{Otra}(t) = S_{NoCreyente}(t) \Rightarrow h_{Catlica}(t) = h_{Otra}(t) = h_{NoCreyente}(t)$.

Hipótesis alternativa: $H_1 : \text{al menos una } S_i(t) \neq S_j(t) \Rightarrow \text{al menos una } h_i(t) \neq h_j(t)$.

Interpretación: Como el p-value es 0.4136, mayor que 0.05, no se rechaza la hipótesis nula. No hay evidencia estadísticamente significativa de diferencias entre las curvas según la religión.

Zona

```
prueba.zona <- survdiff(so.1 ~ zona_cat, data = datos)
prueba.zona$pvalue
```

Hipótesis nula: $H_0 : S_{Urbana}(t) = S_{Rural}(t) \Rightarrow h_{Urbana}(t) = h_{Rural}(t)$.

Hipótesis alternativa: $H_1 : S_{Urbana}(t) \neq S_{Rural}(t) \Rightarrow h_{Urbana}(t) \neq h_{Rural}(t)$.

Interpretación: Como el p-value es 0.5757, mayor que 0.05, no se rechaza la hipótesis nula. No hay evidencia estadísticamente significativa de diferencias entre las curvas de las zonas urbana y rural.

Ejercicio 8

En `survdif()`, `rho = 0` corresponde a la prueba log-rank y `rho = 1` corresponde a la prueba Peto-Peto.

```
survdif(
  so.1 ~ sexo_cat,
  data = datos,
  rho = 1
)$pvalue
```

Interpretación: La prueba log-rank produce un p-value de 0.0084 y la prueba Peto-Peto un p-value de 0.0004. Ambos valores son menores que 0.05, por lo que con ambas pruebas se rechaza la hipótesis nula de igualdad entre las curvas de supervivencia de hombres y mujeres. Por tanto, la prueba Peto-Peto conduce a la misma conclusión que la prueba log-rank: existen diferencias estadísticamente significativas por sexo en la edad a la primera unión conyugal.