

Tarea 2

SP-1637 Análisis de Supervivencia — IIC-2026

Gustavo Murillo

Mario Alvarado

29 de septiembre de 2026

Contenidos

Datos	2
Base de datos	2
Creación de variables	2
Objeto de supervivencia	4
Ejercicio 1	4
Modelo de riesgos proporcionales de Cox	4
Ejercicio 2	5
Ejercicio 3	7
Ejercicio 4	8
Gráfico de residuos de deviancia	8
Identificación de los valores extremos	9
Ejercicio 5	11
Residuos de Cox-Snell	11
Comparación sin valores extremos	13
Ejercicio 6	15
Expansión del archivo en años-persona	15
Recodificación del tiempo	16
Modelo logístico con efectos aleatorios	17
Comparación entre Cox y tiempo discreto	18

Datos

Base de datos

```
pacman::p_load(haven, dplyr, survival, survminer, patchwork, splines, car, lme4)

datos <- read_dta("encfec2010.dta") |>
  filter(region == 1 | region == 8)

summary(datos)
```

region	zona	r201a	r201b
Min. :1.000	Min. :1.000	Min. : 1.00	Min. : 1.000
1st Qu.:1.000	1st Qu.:1.000	1st Qu.: 7.00	1st Qu.: 7.000
Median :1.000	Median :1.000	Median :14.00	Median : 9.000
Mean :1.709	Mean :1.158	Mean :14.94	Mean : 7.927
3rd Qu.:1.000	3rd Qu.:1.000	3rd Qu.:22.00	3rd Qu.:10.000
Max. :8.000	Max. :2.000	Max. :31.00	Max. :99.000

r201c	r202	r204	ednivel	r209
Min. :1930	Min. :15.00	Min. :1.000	Min. : 0.00	Min. :1.000
1st Qu.:1960	1st Qu.:21.00	1st Qu.:1.000	1st Qu.:10.00	1st Qu.:1.000
Median :1977	Median :32.00	Median :1.000	Median :20.00	Median :1.000
Mean :1973	Mean :36.52	Mean :1.498	Mean :24.55	Mean :1.961
3rd Qu.:1988	3rd Qu.:50.00	3rd Qu.:2.000	3rd Qu.:40.00	3rd Qu.:2.000
Max. :1995	Max. :80.00	Max. :2.000	Max. :99.00	Max. :9.000

r215	r216m	r216a	id
Min. :1.000	Min. : 1.00	Min. :1949	Min. : 1
1st Qu.:1.000	1st Qu.: 4.00	1st Qu.:1980	1st Qu.: 562
Median :2.000	Median : 8.00	Median :1995	Median :1100
Mean :1.754	Mean :21.93	Mean :2868	Mean :1188
3rd Qu.:2.000	3rd Qu.:12.00	3rd Qu.:2005	3rd Qu.:1675
Max. :9.000	Max. :99.00	Max. :9999	Max. :3195
	NAs :635	NAs :635	

```
table(datos$region)
```

```
1      8
1554 175
```

Creación de variables

```
datos <- datos |>
  mutate(
    r201b = as.numeric(na_if(r201b, 99)),
    r201c = as.numeric(na_if(r201c, 9999)),
    r216m = if_else(r216m %in% c(98, 99), NA, as.numeric(r216m)),
```

```

r216a = if_else(r216a %in% c(9998, 9999), NA, as.numeric(r216a)),
evento = case_when(
  r215 == 1 ~ 0,
  r215 %in% c(2, 3) ~ 1
),
tiempo_union = case_when(
  evento == 0 ~ as.numeric(r202),
  evento == 1 ~ ((r216a - r201c) * 12 + (r216m - r201b)) / 12
)
)

summary(datos$r201b)

```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NAs
1.000	7.000	9.000	7.874	10.000	12.000	1

```
summary(datos$r216m)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NAs
1.000	4.000	7.000	6.814	10.000	12.000	815

```
table(datos$r215, datos$evento, useNA = "ifany")
```

	0	1	<NA>
1	634	0	0
2	0	892	0
3	0	202	0
9	0	0	1

```
summary(datos$tiempo_union)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NAs
9.00	18.00	21.33	23.61	25.94	79.00	201

```

datos <- datos |>
mutate(
  ednivel_cat = factor(case_when(
    ednivel <= 10 ~ "Primaria o menos",
    ednivel <= 30 ~ "Secundaria",
    ednivel <= 50 ~ "Postsecundaria"
  )),
  religion_cat = factor(case_when(
    r209 == 1 ~ "Católica",
    r209 %in% c(2, 3, 4, 5, 7) ~ "Otra religión",
    r209 == 8 ~ "No creyente"
  )),

```

```

sexo_cat = factor(
  r204,
  levels = c(1, 2),
  labels = c("Hombre", "Mujer")
),
zona_cat = case_when(
  zona == 1 ~ "Urbana",
  zona == 2 ~ "Rural"
),
ednivel = na_if(ednivel, 99)
)

```

Objeto de supervivencia

```
so.1 <- Surv(time = datos$tiempo_union, event = datos$evento)
```

Ejercicio 1

1. Estime un modelo de riesgos proporcionales de Cox para analizar simultáneamente las diferencias en el riesgo (hazard) de la primera unión según nivel de educación (variable cuantitativa discreta) y religión y sexo (variables cualitativas). Interprete los hazard ratios estimados. (20 pts)

Modelo de riesgos proporcionales de Cox

```

mod_rp_cox <- coxph(
  so.1 ~ ednivel + religion_cat + sexo_cat,
  data = datos
)
summary(mod_rp_cox)

```

Call:

```
coxph(formula = so.1 ~ ednivel + religion_cat + sexo_cat, data = datos)
```

```

n= 1525, number of events= 892
(204 observations deleted due to missingness)

```

	coef	exp(coef)	se(coef)	z	Pr(> z)
ednivel	-0.011196	0.988867	0.002012	-5.565	2.61e-08 ***
religion_catNo creyente	-0.019787	0.980407	0.131536	-0.150	0.880
religion_catOtra religión	0.103315	1.108841	0.079123	1.306	0.192
sexo_catMujer	0.355518	1.426920	0.068309	5.205	1.94e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

	exp(coef)	exp(-coef)	lower .95	upper .95
ednivel	0.9889	1.0113	0.9850	0.9928

religion_catNo creyente	0.9804	1.0200	0.7576	1.2687
religion_catOtra religión	1.1088	0.9018	0.9496	1.2948
sexo_catMujer	1.4269	0.7008	1.2481	1.6313

```

Concordance= 0.631 (se = 0.011 )
Likelihood ratio test= 64.58 on 4 df, p=3e-13
Wald test = 63.75 on 4 df, p=5e-13
Score (logrank) test = 64.41 on 4 df, p=3e-13

```

```
(0.9889 - 1) * 100 # ednivel
```

```
[1] -1.11
```

```
(0.9804 - 1) * 100 # no creyente
```

```
[1] -1.96
```

```
(1.1088 - 1) * 100 # Otra religión
```

```
[1] 10.88
```

```
(1.4269 - 1) * 100 # sexo mujer
```

```
[1] 42.69
```

Interpretación

Significativos

- Por cada unidad adicional en el nivel educativo, el hazard de la primera unión disminuye en 1,11 %. Lo anterior, manteniendo las demás variables constantes.
- Para las mujeres, el hazard de la primera unión es 42,69 % mayor que para los hombres . Lo anterior, manteniendo las demás variables constantes.

No significativos

- Para las personas que **no** son creyentes, el hazard de la primera unión es 1,96 % menor que para las personas que son creyentes. Lo anterior, manteniendo las demás variables constantes.
- Para las personas que pertenecen a **otra religión**, el hazard de la primera unión es 10,88 % mayor que para las personas que son creyentes. Lo anterior, manteniendo las demás variables constantes.

Ejercicio 2

2. Con gráficos de proporcionalidad, analice el supuesto de riesgos proporcionales para las distintas variables. Escriba en pocas oraciones qué observa sobre el cumplimiento de los supuestos. (10 pts)

```


datos$No_creyente <- 1 * (datos$religion_cat == "No creyente")
datos$Otra_reli <- 1 * (datos$religion_cat == "Otra religión")

cox_2 <- coxph(
  so.1 ~ ednivel + No_creyente + Otra_reli + sexo_cat,
  data = datos
)

p_rp <- cox.zph(cox_2)
ggcoxzph(p_rp)

```

Global Schoenfeld Test p: 4.425e-20



💡 Interpretación

- Con respecto al nivel educativo, no parece cumplirse el supuesto de riesgos proporcionales ya que se observa que la línea es más bien creciente y parece que conforme aumenta la edad, el riesgo de la primera unión cambia.
- En lo que respecta a las personas **no** creyentes, sí parece cumplirse el supuesto de riesgos proporcionales ya que se observa que la línea sí es prácticamente horizontal y que conforme aumenta la edad, para estas personas el riesgo de la primera unión se mantiene constante en comparación con los católicos. Lo mismo sucede para las personas que tienen una religión distinta a la católica.
- Para las mujeres, el supuesto de riesgos proporcionales tampoco parece cumplirse. Se observa que la línea es decreciente en el tiempo, es decir, que conforme aumenta la edad de las mujeres, parece que el riesgo de la primera unión disminuye en comparación con los hombres.

Ejercicio 3

Con un 5% de significancia, analice el supuesto de riesgos proporcionales con la prueba de hipótesis basada en los residuos de Schoenfeld (la prueba de hipótesis estudiada en clase). Diga si los resultados de la prueba coinciden con su análisis gráfico. Por qué sí o por qué no? . Si no se cumple el supuesto, corrija el modelo con la función `tt`, decidiendo si toma la variable entera o usa “nudos” (“`knotts`”) (10 pts.)

```
cox.zph(cox_2)
```

	chisq	df	p
ednivel	46.592	1	8.7e-12
No_creyente	1.652	1	0.2
Otra_reli	0.274	1	0.6
sexo_cat	44.801	1	2.2e-11
GLOBAL	96.931	4	< 2e-16

```
cox.zph(mod_rp_cox)
```

	chisq	df	p
ednivel	46.59	1	8.7e-12
religion_cat	1.76	2	0.42
sexo_cat	44.80	1	2.2e-11
GLOBAL	96.93	4	< 2e-16

Interpretación

- Para el modelo global, hay suficiente evidencia estadística para rechazar la hipótesis nula de que para el modelo en su conjunto el supuesto de riesgos proporcionales se cumple.
- Para el factor de religión, **no** se rechaza la hipótesis nula de que el coeficiente de religión cambie en función del tiempo. Es decir se cumple el supuesto de riesgos proporcionales.
- Para el nivel educativo, existe suficiente evidencia estadística para rechazar la hipótesis nula de que se cumple el supuesto de riesgos proporcionales. Es decir, según el nivel educativo del individuo, el riesgo de la primera unión cambia con el tiempo.
- Con respecto al sexo, con un alfa de 0,05 , se rechaza la hipótesis nula de que el supuesto de riesgos proporcionales se cumple. Por tanto, según el sexo del individuo, el riesgo de la primera unión cambia a lo largo del tiempo.
- Los resultados de la prueba formal concuerdan con lo que se observó gráficamente en el ejercicio anterior. En los gráficos donde hubo líneas crecientes o decrecientes fue en los correspondientes a las variables en las que no se cumplió el supuesto de riesgos proporcionales (nivel educativo y sexo).

```
cox_corregido <- coxph(  
  so.1 ~ ednivel +  
    No_creyente +  
    Otra_reli +  
    sexo_cat +  
    tt(sexo_cat) +  
    tt(ednivel),
```

```

tt = list(
  function(x, t, ...) {
    as.numeric(x) * t
  },
  function(x, t, ...) {
    as.numeric(x) * nsk(t, knots = c(20, 25, 30))
  }
),
data = datos
)

```

i Nota

- Para la variable sexo, se decide tomar la variable entera ya que la tendencia decreciente en el tiempo es muy marcada y a un ritmo constante.
- Por su parte, para nivel educativo se decide usar nudos ya que en realidad la línea es más como una curva con un crecimiento a un ritmo que no es constante. Esto quiere decir que en realidad la tasa de cambio del riesgo no crece uniformemente si no que en algunas edad crece más rápido o más lento.

Ejercicio 4

Con un gráfico de residuos de deviancia vs el componente lineal ajustado, analice si hay valores extremos. Utilice los valores frontera de -2 y 2 para definir a los valores extremos. Si encuentra valores extremos, diseñe una tabla en la que incluya el componente lineal ajustado, el residuo de deviancia, y los valores de educación y año de nacimiento (cohorte), y diga por qué son valores extremos. Si encuentra más de 10 valores extremos, puede seleccionar una submuestra para describirlos. (20 pts.)


Gráfico de residuos de deviancia

```

res_dev <- residuals(mod_rp_cox, type = "deviance")
xb <- predict(mod_rp_cox, type = "lp")

plot(
  res_dev ~ xb,
  xlab = "Componente lineal ajustado",
  ylab = "Residuos de deviancia",
  ylim = range(c(res_dev, -2, 2))
)
abline(h = c(-2, 2), col = "red", lty = 2, lwd = 2)

```



Los residuos que se encuentran por encima de 2 o por debajo de -2 se consideran valores extremos. A diferencia de una regresión lineal, en este gráfico no se busca verificar homoscedasticidad, sino identificar observaciones que el modelo predice de manera deficiente.

Identificación de los valores extremos

```
# Los nombres de los residuos indican las filas utilizadas por el modelo.
filas_modelo <- as.integer(names(res_dev))

tabla_extremos <- datos[filas_modelo, ] |>
  mutate(
    componente_lineal = as.numeric(xb),
    residuo_deviancia = as.numeric(res_dev),
    educacion = as.character(as_factor(ednivel)),
    cohorte = as.numeric(r201c)
  ) |>
  filter(abs(residuo_deviancia) > 2) |>
  arrange(desc(abs(residuo_deviancia)))

resumen_extremos <- data.frame(
  Medida = c(
    "Observaciones utilizadas por el modelo",
    "Valores extremos",
    "Porcentaje de valores extremos"
  ),
  Resultado = c(
    length(res_dev),
    nrow(tabla_extremos),
    paste0(round(100 * nrow(tabla_extremos) / length(res_dev), 2), "%")
  )
)
```

```
knitr::kable(resumen_extremos, align = c("l", "r"))
```

Medida	Resultado
Observaciones utilizadas por el modelo	1525
Valores extremos	112
Porcentaje de valores extremos	7.34%

Como se encontraron más de 10 valores extremos, se presentan los 10 casos con el mayor valor absoluto del residuo de deviancia.

```
tabla_extremos |>
  slice_head(n = 10) |>
  transmute(
    ID = id,
    `Componente lineal` = round(componente_lineal, 3),
    `Residuo de deviancia` = round(residuo_deviancia, 3),
    Educacion = educacion,
    Cohorte = cohorte,
    `Edad a la union o censura` = round(tiempo_union, 2),
    Evento = evento
  ) |>
  knitr::kable(align = c("r", "r", "r", "l", "r", "r", "r"))
```

ID	Componente lineal	Residuo de deviancia	Educacion	Cohorte	Edad a la union o censura	Evento
1109	0.528	3.474	primaria	1950	9.00	1
235	0.631	3.237	primaria	1959	12.00	1
80	0.508	3.148	primaria	1967	12.08	1
914	0.528	3.049	primaria	1995	12.83	1
305	0.040	2.941	secundaria académica	1985	13.75	1
2214	0.640	2.938	ninguno	1993	12.92	1
815	0.743	-2.918	ninguno	1938	71.00	0
2572	0.631	2.878	primaria	1980	13.25	1
1513	0.519	2.863	secundaria académica	1963	13.33	1
572	0.152	2.833	primaria	1992	13.92	1

Interpretación

- Se encontraron 112 valores extremos de las 1525 observaciones utilizadas por el modelo, lo que representa aproximadamente un 7,34 % de los casos.
- Los residuos positivos indican que la primera unión ocurrió antes de lo esperado por el modelo, dadas las características de la persona. En la submuestra presentada, nueve casos tienen residuos positivos y experimentaron la primera unión a edades muy tempranas, aproximadamente entre los 9 y 14 años.
- El caso con residuo negativo corresponde a una persona censurada a los 71 años. Esta persona

permaneció sin experimentar una primera unión durante mucho más tiempo del esperado por el modelo.

- Estos casos son extremos porque su experiencia observada difiere considerablemente de la predicha por el modelo. Esto no significa necesariamente que sean errores en la base de datos, sino que las variables incluidas en el modelo no explican adecuadamente su tiempo hasta la primera unión.

Ejercicio 5

Con los residuos de Cox-Snell, analice la bondad de ajuste del modelo a los datos. Si hay un mal ajuste, diga si los valores extremos encontrados en el punto anterior son los que están causando el mal ajuste (20 pts.)

Residuos de Cox-Snell

Los residuos de Cox-Snell no se obtienen directamente con `residuals()`. Siguiendo el procedimiento visto en clase, se calculan restando el residuo de martingala a la variable de evento:


$$[r_{\{Ci\}} = i - r_{\{Mi\}}]$$

Si el modelo tiene un buen ajuste, los residuos de Cox-Snell deben aproximarse a una distribución exponencial con parámetro 1.

```
martingala <- residuals(mod_rp_cox, type = "martingale")
evento_modelo <- datos$evento[filas_modelo]
cox_snell <- evento_modelo - martingala

hist(
  cox_snell,
  xlab = "Residuos de Cox-Snell",
  ylab = "Frecuencia absoluta",
  main = "Histograma de los residuos de Cox-Snell"
)
```


Histograma de los residuos de Cox-Snell



Para analizar la bondad de ajuste se comparan los residuos con los cuantiles de una distribución exponencial. Los puntos deberían seguir aproximadamente la línea central del QQPlot y permanecer dentro de las bandas de confianza.

```
qqPlot(  
  cox_snell,  
  distribution = "exp",  
  main = "QQPlot de los residuos de Cox-Snell",  
  xlab = "Cuantiles de la distribución exponencial",  
  ylab = "Residuos de Cox-Snell",  
  id = FALSE  
)
```

QQPlot de los residuos de Cox-Snell



Comparación sin valores extremos

Para determinar si los valores extremos encontrados en el ejercicio anterior explican el mal ajuste, se vuelve a estimar el modelo después de excluirlos y se comparan ambos QQPlots.

```
filas_extremas <- filas_modelo[abs(res_dev) > 2]
datos_sin_extremos <- datos[-filas_extremas, ]

mod_sin_extremos <- coxph(
  Surv(tiempo_union, evento) ~ ednivel + religion_cat + sexo_cat,
  data = datos_sin_extremos
)

martingala_sin <- residuals(mod_sin_extremos, type = "martingale")
filas_modelo_sin <- as.integer(names(martingala_sin))
evento_modelo_sin <- datos_sin_extremos$evento[filas_modelo_sin]
cox_snell_sin <- evento_modelo_sin - martingala_sin

par(mfrow = c(1, 2))


qqPlot(
  cox_snell,
  distribution = "exp",
  main = "Modelo original",
  xlab = "Cuantiles exponenciales",
  ylab = "Residuos de Cox-Snell",
  id = FALSE
)

qqPlot(
```

```

cox_snell_sin,
distribution = "exp",
main = "Modelo sin valores extremos",
xlab = "Cuantiles exponenciales",
ylab = "Residuos de Cox-Snell",
id = FALSE
)

```



```

par(mfrow = c(1, 1))

```

💡 Interpretación

- En el modelo original, la mayor parte de los residuos sigue aproximadamente la línea central. Sin embargo, en la cola superior se observa una separación sistemática, por lo que el ajuste es razonable para los valores centrales, pero no es completamente satisfactorio para las observaciones con residuos altos.
- Después de excluir los 112 valores extremos y volver a estimar el modelo, la separación en la cola superior no desaparece; por el contrario, continúa siendo visible y algunos residuos se alejan todavía más de la línea central.
- Por tanto, los valores extremos detectados en el ejercicio 4 no parecen ser la causa principal del problema de ajuste. La falta de ajuste puede estar relacionada con la especificación del modelo, con variables explicativas no incluidas o con el incumplimiento del supuesto de riesgos proporcionales detectado anteriormente para educación y sexo.

Ejercicio 6

Expanda el archivo de datos para definirlo en años-persona. Con una regresión logística con efectos aleatorios, estime un modelo de riesgos proporcionales en tiempo discreto. Haga un cuadro comparativo en el que compare los hazard ratios del modelo de Cox con los Odds Ratios del modelo logístico. Escriba a la par de los mismos un asterisco si el coeficiente exponenciado es distinto de cero al 5% de significancia (o sea, si el pvalue es menor a 0.05). Escriba un brevísimo párrafo que compare los resultados tanto descriptivos como inferenciales. (20 pts.)

Expansión del archivo en años-persona

Primero se conservan las mismas observaciones utilizadas por el modelo de Cox. Luego cada persona se repite una vez por cada año durante el cual estuvo expuesta al riesgo de experimentar la primera unión.

```
datos_modelo <- datos[filas_modelo, ]
datos_modelo$id_panel <- seq_len(nrow(datos_modelo))
datos_modelo$periodos <- pmax(
  1L,
  as.integer(ceiling(datos_modelo$tiempo_union))
)

datos_ap <- datos_modelo[
  rep(seq_len(nrow(datos_modelo)), datos_modelo$periodos),
]

datos_ap$edad_final <- sequence(datos_modelo$periodos)
datos_ap$edad_inicial <- datos_ap$edad_final - 1L
```

En los años anteriores a la primera unión, la variable `evento_anual` es igual a 0. Para las personas que experimentaron el evento, toma el valor 1 únicamente en el último intervalo. Las personas censuradas mantienen el valor 0 durante todo el seguimiento.

```
datos_ap$evento_anual <- as.integer(
  datos_ap$evento == 1 &
  datos_ap$edad_final == datos_ap$periodos
)

resumen_expansion <- data.frame(
  Medida = c(
    "Personas",
    "Registros año-persona",
    "Eventos en la base original",
    "Eventos en la base expandida"
  ),
  Resultado = c(
    nrow(datos_modelo),
    nrow(datos_ap),
    sum(datos_modelo$evento),
    sum(datos_ap$evento_anual)
  )
)
```

```
knitr::kable(resumen_expansion, align = c("l", "r"))
```

Medida	Resultado
Personas	1525
Registros año-persona	36410
Eventos en la base original	892
Eventos en la base expandida	892

La expansión genera 36410 registros año-persona y conserva los 892 eventos de la base original.

Recodificación del tiempo

El tiempo se incorpora como factor para permitir que el riesgo basal cambie entre grupos de edades. Las edades con pocos eventos se agrupan para evitar estimaciones inestables: 14 años o menos, intervalos quinquenales entre 15 y 39 años, y 40 años o más.

```
datos_ap <- datos_ap |>
  mutate(
    edad_tramo = cut(
      edad_final,
      breaks = c(-Inf, 14, 19, 24, 29, 34, 39, Inf),
      labels = c(
        "14 o menos",
        "15-19",
        "20-24",
        "25-29",
        "30-34",
        "35-39",
        "40 o mas"
      )
    )
  )

tabla_tiempo <- datos_ap |>
  group_by(edad_tramo) |>
  summarise(
    Registros_año_persona = n(),
    Eventos = sum(evento_anual),
    .groups = "drop"
  )

knitr::kable(tabla_tiempo, align = c("l", "r", "r"))
```

edad_tramo	Registros_año_persona	Eventos
14 o menos	21340	12
15-19	6602	183
20-24	3972	352
25-29	1881	196
30-34	1004	72

edad_tramo	Registros_año_persona	Eventos
35-39	592	52
40 o mas	1019	25

Modelo logístico con efectos aleatorios

Se estima una regresión logística mixta. El intercepto aleatorio por persona toma en cuenta que los distintos años correspondientes a una misma persona no son observaciones independientes. Los coeficientes de educación, religión y sexo se mantienen constantes en el tiempo, mientras que `edad_tramo` representa el riesgo basal discreto.

```
mod_logit <- glmer(
  evento_anual ~ ednivel +
    religion_cat +
    sexo_cat +
    edad_tramo +
    (1 | id_panel),
  family = binomial(link = "logit"),
  data = datos_ap,
  nAGQ = 0,
  control = glmerControl(
    optimizer = "bobyqa",
    optCtrl = list(maxfun = 200000)
  )
)

summary(mod_logit)
```

```
Generalized linear mixed model fit by maximum likelihood (Adaptive
Gauss-Hermite Quadrature, nAGQ = 0) [glmerMod]
Family: binomial ( logit )
Formula: evento_anual ~ ednivel + religion_cat + sexo_cat + edad_tramo +
(1 | id_panel)
Data: datos_ap
Control: glmerControl(optimizer = "bobyqa", optCtrl = list(maxfun = 2e+05))
```

AIC	BIC	logLik	-2*log(L)	df.resid
6569.2	6671.3	-3272.6	6545.2	36398

Scaled residuals:

Min	1Q	Median	3Q	Max
-0.496	-0.176	-0.028	-0.021	39.965

Random effects:

Groups	Name	Variance	Std.Dev.
id_panel	(Intercept)	0.3822	0.6182

Number of obs: 36410, groups: id_panel, 1525

Fixed effects:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-7.452110	0.300265	-24.818	< 2e-16 ***

```

ednivel          -0.015057    0.002458   -6.127 8.98e-10 ***
religion_catNo creyente -0.001615    0.156003   -0.010  0.992
religion_catOtra religión 0.112521    0.095908    1.173  0.241
sexo_catMujer       0.481879    0.082561    5.837 5.33e-09 ***
edad_tramo15-19      3.968017    0.298346   13.300 < 2e-16 ***
edad_tramo20-24      5.352012    0.294757   18.157 < 2e-16 ***
edad_tramo25-29      5.726152    0.300132   19.079 < 2e-16 ***
edad_tramo30-34      5.427002    0.316272   17.159 < 2e-16 ***
edad_tramo35-39      5.737000    0.327080   17.540 < 2e-16 ***
edad_tramo40 o mas    4.515884    0.361033   12.508 < 2e-16 ***

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Correlation of Fixed Effects:

```

              (Intr) ednivl rlg_Nc rlg_Or sx_ctM e_15-1 e_20-2 e_25-2 e_30-3
ednivel      -0.185
rlgn_ctNcry  -0.082  0.011
rlgn_ctOtrr  -0.093  0.037  0.155
sexo_catMjr  -0.163 -0.016  0.132 -0.059
edd_tr15-19  -0.930 -0.010  0.005  0.001  0.007
edd_tr20-24  -0.942 -0.030  0.012  0.006  0.029  0.949
edd_tr25-29  -0.929 -0.032  0.011  0.015  0.043  0.932  0.947
edd_tr30-34  -0.883 -0.021  0.010  0.018  0.036  0.884  0.899  0.889
edd_tr35-39  -0.855 -0.013  0.003  0.021  0.032  0.855  0.868  0.859  0.822
edd_trm40om  -0.776  0.001  0.016  0.031  0.017  0.774  0.786  0.777  0.743
              e_35-3
ednivel
rlgn_ctNcry
rlgn_ctOtrr
sexo_catMjr
edd_tr15-19
edd_tr20-24
edd_tr25-29
edd_tr30-34
edd_tr35-39
edd_trm40om  0.727

```

Comparación entre Cox y tiempo discreto

```

coef_cox <- summary(mod_rp_cox)$coefficients[1:4, , drop = FALSE]
coef_logit <- summary(mod_logit)$coefficients[2:5, , drop = FALSE]

agregar_asterisco <- function(valor, pvalor) {
  paste0(
    formatC(valor, format = "f", digits = 3),
    ifelse(pvalor < 0.05, "*", "")
  )
}

tabla_comparacion <- data.frame(

```

```

Covariable = c(
  "Nivel educativo",
  "No creyente vs. católica",
  "Otra religión vs. católica",
  "Mujer vs. hombre"
),
`HR de Cox` = agregar_asterisco(
  exp(coef_cox[, "coef"]),
  coef_cox[, "Pr(>|z|)"]
),
`OR logístico` = agregar_asterisco(
  exp(coef_logit[, "Estimate"]),
  coef_logit[, "Pr(>|z|)"]
),
check.names = FALSE
)

knitr::kable(tabla_comparacion, align = c("l", "r", "r"))

```

Covariable	HR de Cox	OR logístico
Nivel educativo	0.989*	0.985*
No creyente vs. católica	0.980	0.998
Otra religión vs. católica	1.109	1.119
Mujer vs. hombre	1.427*	1.619*

El asterisco indica un p-valor menor que 0,05. Técnicamente, la prueba establece si el coeficiente es distinto de 0, lo que equivale a determinar si el HR o el OR es distinto de 1.

Interpretación

- Ambos modelos presentan las mismas direcciones y conclusiones inferenciales. El nivel educativo tiene una asociación negativa y estadísticamente significativa con el riesgo de la primera unión: el HR de Cox es 0,989 y el OR del modelo logístico es 0,985.
- Las categorías de religión no son estadísticamente significativas en ninguno de los dos modelos. Sus intervalos de HR y OR incluyen el 1.
- Ser mujer está asociado con una mayor ocurrencia de la primera unión en ambos modelos. El modelo de Cox estima un HR de 1,427 y el modelo logístico un OR de 1,619; ambos resultados son estadísticamente significativos.
- Los valores no tienen que ser idénticos porque Cox estima razones de hazards en tiempo continuo y la regresión logística estima razones de odds por intervalo anual. Aún así, la coincidencia en dirección y significancia muestra que las conclusiones sustantivas son consistentes entre ambas estrategias.