Tarea 3

SP-1637 Análisis de Sobrevivencia — IIC-2026

Gustavo Murillo Mario Alvarado

27 de octubre de 2026

Contenidos

Pregunta 1 . . . 2
Pregunta 2 . . . 3
Pregunta 3 . . . 4
Modelo loglogístico . . . 4
Modelo de Cox . . . 5
Pregunta 4 . . . 7
Pregunta 5 . . . 7
Pregunta 6 . . . 9
Weibull . . . 9
Exponencial . . . 10
Gaussiana . . . 11
Lognormal . . . 11
Logística . . . 12
Loglogística . . . 12
Comparación . . . 13
Pregunta 7 . . . 13

Utilice el archivo de encuesta de fecundidad que usó para la primera tarea. Use además las variables que creó: nivel de educación, religión y sexo. Puede usar zona pero no es obligatorio

```
pacman::p_load(haven,dplyr,visreg,casebase,splines,ggplot2,survival,flexsurv,boot,boot.pval)
```

```
datos <- read_dta("data/encfec2010.dta")
datos <- datos |>
  mutate(
    r201b = as.numeric(na_if(r201b, 99)),
    r201c = as.numeric(na_if(r201c, 9999)),
    r216m = if_else(r216m %in% c(98, 99), NA, as.numeric(r216m)),
    r216a = if_else(r216a %in% c(9998, 9999), NA, as.numeric(r216a)),
    evento = case_when(
      r215 == 1 ~ 0,
      r215 %in% c(2, 3) ~ 1
    ),
    tiempo_union = case_when(
      evento == 0 ~ as.numeric(r202),
      evento == 1 ~ ((r216a - r201c) * 12 + (r216m - r201b)) / 12
    )
```

```
  )
```

```
datos <- datos |>
  mutate(
    ednivel_cat = factor(case_when(
      ednivel <= 10 ~ "Primaria o menos",
      ednivel <= 30 ~ "Secundaria",
      ednivel <= 50 ~ "Postsecundaria"
    )),

    religion_cat = factor(case_when(
      r209 == 1 ~ "Católica",
      r209 %in% c(2, 3, 4, 5, 7) ~ "Otra religión",
      r209 == 8 ~ "No creyente"
    )),
    sexo_cat = factor(
      r204,
      levels = c(1, 2),
      labels = c("Hombre", "Mujer")
    ),
    zona_cat = case_when(
      zona == 1 ~ "Urbana",
      zona == 2 ~ "Rural"
    ),
    ednivel = na_if(ednivel, 99)
  )
```

Conteste las siguientes preguntas

Pregunta 1

Haga un gráfico de la curva de hazards para la edad a la primera unión con la función fitSmoothHazard o la alternativa que vimos en clase y, a partir de la forma, argumente cuál sería la distribución paramétrica que ajusta mejor a la curva de hazards. (10 ptos)

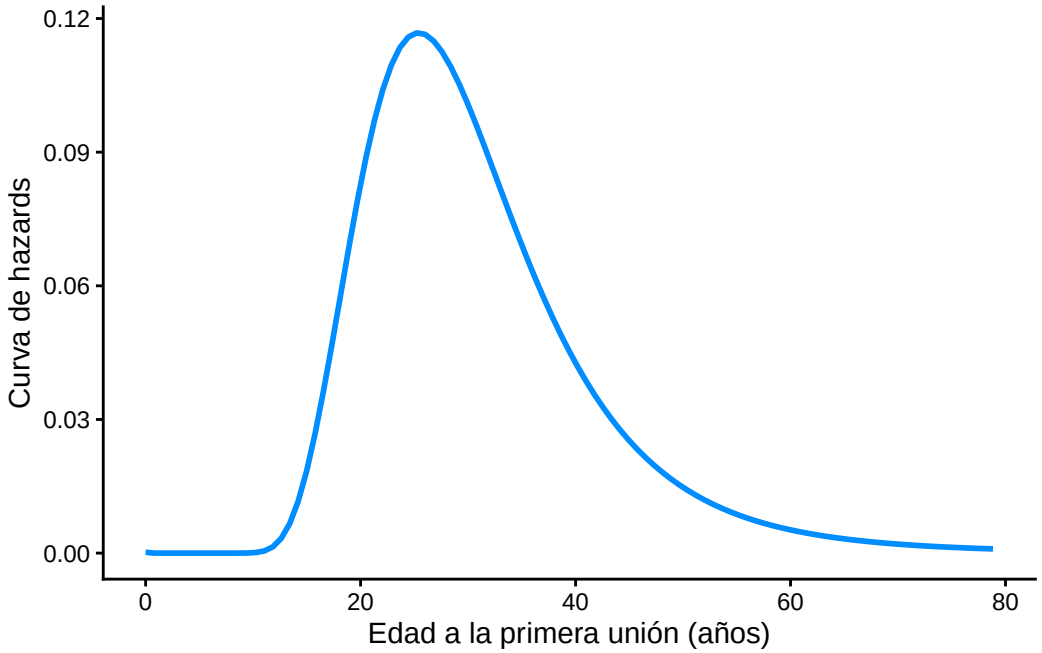
```
datos_hazard <- datos |>
  filter(!is.na(evento), is.finite(tiempo_union), tiempo_union > 0)

mod1 <- fitSmoothHazard(evento ~ ns(log(tiempo_union), df = 4),
                        data = datos_hazard,
                        time = "tiempo_union")

plot(
  mod1,
  hazard.params = list(
    xvar = "tiempo_union"
  )
) +
  labs(
    x = "Edad a la primera unión (años)",
    y = "Curva de hazards"
  )+
```

```
    theme_classic()
```

```
Conditions used in construction of plot
offset: 0
```



La curva presenta una forma en la que esta aumenta rápido al inicio y luego disminuye, como la forma de una campana con cierta asimetría positiva. Este comportamiento sugiere que la distribución podría ser una lognormal o una loglogística

Pregunta 2

Estime varios modelos paramétricos con las distribuciones disponibles en R, y haga una tabla con los AICs correspondientes a cada modelo estimado. Incluya todas las predictoras que se vienen usando desde la tarea 1. Diga cuál es la distribución que mejor ajusta a sus hazards de acuerdo con el AIC, y diga si concuerda con su conclusión del punto 1 (10 ptos)

```
# Se utiliza la misma muestra en todos los modelos para comparar los AIC.
datos_modelos <- datos |>
  filter(!is.na(evento), is.finite(tiempo_union), tiempo_union > 0,
         !is.na(ednivel_cat), !is.na(religion_cat), !is.na(sexo_cat))

surv1 <- Surv(time = datos_modelos$tiempo_union,
              event = datos_modelos$evento)

weib.1 = survreg(surv1 ~ ednivel_cat + religion_cat + sexo_cat,
                 data = datos_modelos, dist = "weibull")

exp.1 = survreg(surv1 ~ ednivel_cat + religion_cat + sexo_cat,
                data = datos_modelos, dist = "exponential")

gauss.1 = survreg(surv1 ~ ednivel_cat + religion_cat + sexo_cat,
                  data = datos_modelos, dist = "gaussian")
```

```r
logn.1 = survreg(surv1 ~ ednivel_cat + religion_cat + sexo_cat,
                 data = datos_modelos, dist = "lognormal")

logist.1 = survreg(surv1 ~ ednivel_cat + religion_cat + sexo_cat,
                   data = datos_modelos, dist = "logistic")

loglog.1 = survreg(surv1 ~ ednivel_cat + religion_cat + sexo_cat,
                   data = datos_modelos, dist = "loglogistic")

gomp.1 = flexsurvreg(surv1 ~ ednivel_cat + religion_cat + sexo_cat,
                     data = datos_modelos, dist = "gompertz")

gamma.1 = flexsurvreg(surv1 ~ ednivel_cat + religion_cat + sexo_cat,
                      data = datos_modelos, dist = "gamma")

tabla.param <- rbind(AIC(weib.1), AIC(exp.1), AIC(gauss.1), AIC(logn.1),
                     AIC(logist.1), AIC(loglog.1), AIC(gomp.1), AIC(gamma.1))

rownames(tabla.param) <- c("Weibull", "Exponencial", "Gaussiana", "Lognormal",
                           "Logística", "LogLogística", "Gompertz", "Gamma")
colnames(tabla.param) <- "AIC"
tabla.param
```

```
                AIC
Weibull      13205.68
Exponencial  15100.78
Gaussiana    13294.50
Lognormal    12170.07
Logística    12828.46
LogLogística 12019.93
Gompertz     14162.56
Gamma        12496.79
```

Entre los modelos evaluados, la distribución loglogística presentó el menor AIC (12019,93), seguida de la lognormal (12170,07). Este resultado concuerda con lo observado en la pregunta 1

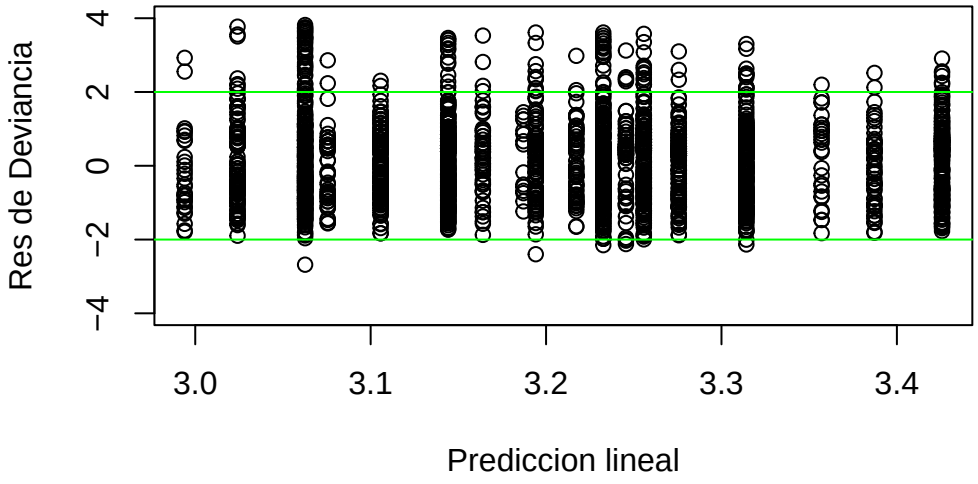
Pregunta 3

Estime residuos de devianza, haga un gráfico de dispersión de los residuos de devianza contra las estimaciones lineales (el linear prediction). Compare este gráfico con un gráfico equivalente, pero con los residuos de deviancia estimadas con un modelo de Cox y conteste en cuál modelo se encuentran residuos de deviancia más extremos. (20 ptos.)

Modelo loglogístico

```r
res.dev.loglog <- residuals(loglog.1, type = "deviance")
xb.loglog <- predict(loglog.1, type = "lp")

plot(res.dev.loglog ~ xb.loglog, xlab = "Prediccion lineal",
     ylab = "Res de Deviancia", ylim = c(-4, 4))
abline(h = c(-2, 2), col = "green")
```

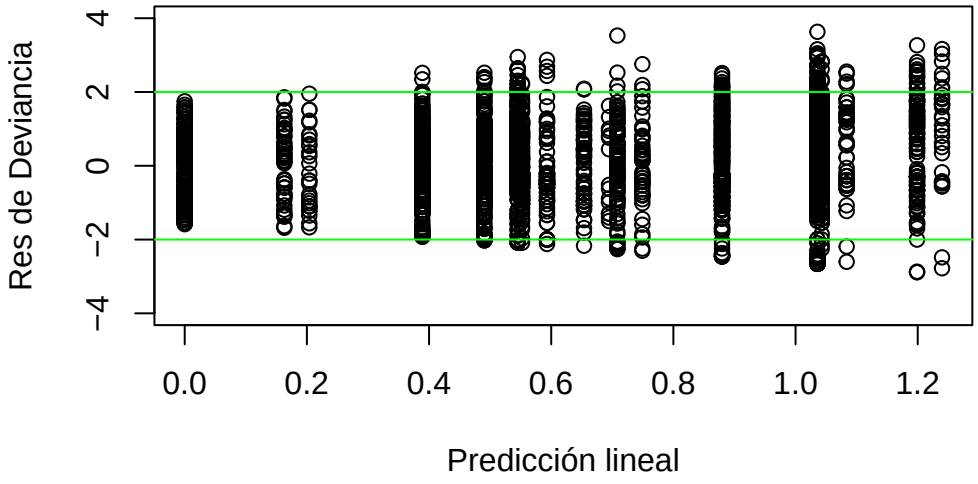


Modelo de Cox

```
cox.1 = coxph(surv1 ~ ednivel_cat + religion_cat + sexo_cat,
              data = datos_modelos)

res.dev.cox <- residuals(cox.1, type = "deviance")
xb.cox <- predict(cox.1, type = "lp")

plot(res.dev.cox ~ xb.cox, xlab = "Predicción lineal",
     ylab = "Res de Deviancia", ylim = c(-4, 4))
abline(h = c(-2, 2), col = "green")
```




```
tabla.residuos <- data.frame(
  Modelo = c("Loglogística", "Cox"),
  Menores_menos2 = c(
    sum(res.dev.loglog < -2),
    sum(res.dev.cox < -2)
  ),
  Mayores_2 = c(
    sum(res.dev.loglog > 2),
    sum(res.dev.cox > 2)
  ),
  Total_extremos = c(
    sum(abs(res.dev.loglog) > 2),
    sum(abs(res.dev.cox) > 2)
  ),
  Porcentaje_extremos = round(c(
    mean(abs(res.dev.loglog) > 2) * 100,
    mean(abs(res.dev.cox) > 2) * 100
  ), 2),
  Maxima_magnitud = round(c(
    max(abs(res.dev.loglog)),
    max(abs(res.dev.cox))
  ), 3)
)

tabla.residuos
```

```
       Modelo Menores_menos2 Mayores_2 Total_extremos Porcentaje_extremos
1 Loglogística              7       142            149                5.43
2          Cox             85       112            197                7.18
  Maxima_magnitud
1           3.816
2           3.632
```

Al hacer el análisis visual, pareciera que la loglogística tuviera más residuos de deviancia extremos, sin embargo, utilizando como referencia los límites −2 y 2, el modelo de Cox presenta una mayor cantidad de residuos de devianza extremos: 197 frente a 149 del modelo loglogístico. No obstante, la loglogística presenta más residuos extremos positivos y el residuo de mayor magnitud absoluta.

Pregunta 4

Con el modelo paramétrico que escogió, estime el percentil 25 y la mediana de edad al uso del primer anticonceptivo, según niveles de educación, y escogiendo un valor fijo (se evaluará cómo lo escogió) para las demás variables predictoras. Haga un cuadro comparativo con dichos percentiles (20 ptos.)

```
# Se fijan sexo y religión en sus categorías más frecuentes en la muestra analizada

tabla.sexo <- table(datos_modelos$sexo_cat)
tabla.religion <- table(datos_modelos$religion_cat)

sexo_fijo <- names(tabla.sexo)[which.max(tabla.sexo)]
religion_fija <- names(tabla.religion)[which.max(tabla.religion)]

nueva <- data.frame(
  ednivel_cat = factor(c("Primaria o menos", "Secundaria", "Postsecundaria"),
                       levels = levels(datos_modelos$ednivel_cat)),
  sexo_cat = factor(rep(sexo_fijo, 3),
                    levels = levels(datos_modelos$sexo_cat)),
  religion_cat = factor(rep(religion_fija, 3),
                        levels = levels(datos_modelos$religion_cat))
)

y3 = predict(loglog.1, newdata = nueva, type = "quantile", p = c(0.5))
y4 = predict(loglog.1, newdata = nueva, type = "quantile", p = c(0.25))

tabla.percentiles <- cbind(nueva, round(cbind(y4, y3), 2))
colnames(tabla.percentiles) <- c("Educación", "Sexo", "Religión",
                                 "Percentil 25(años)", "Mediana(años)")
tabla.percentiles
```

```
         Educación   Sexo Religión Percentil 25(años) Mediana(años)
1 Primaria o menos Hombre Católica              20.93         25.35
2       Secundaria Hombre Católica              22.71         27.50
3   Postsecundaria Hombre Católica              25.39         30.75
```

Según el modelo loglogístico, para hombres de religión católica, las edades estimadas a la primera unión aumentan con el nivel educativo, tanto en el percentil 25 como en la mediana.

Pregunta 5

Usando la ecuación estimada del modelo paramétrico preferido, haga un gráfico en el que compare las curvas de hazard por sexo manteniendo constante las demás variables. Diga si la forma de las curvas se parece a la estimada en el punto 1. (10 ptos.)

```
tabla.educacion <- table(datos_modelos$ednivel_cat)
tabla.religion <- table(datos_modelos$religion_cat)
educacion_fija <- names(tabla.educacion)[which.max(tabla.educacion)]
```

```r
religion_fija <- names(tabla.religion)[which.max(tabla.religion)]

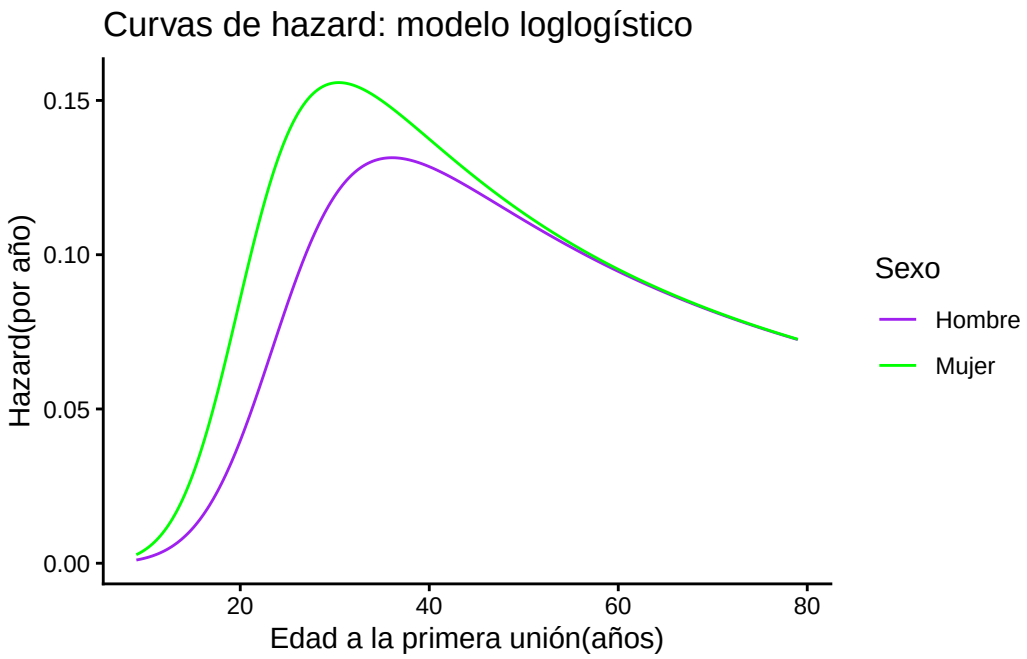

tiempos <- seq(min(datos_modelos$tiempo_union),
               max(datos_modelos$tiempo_union), length.out = 500)

nueva.haz <- data.frame(
  ednivel_cat = factor(rep(educacion_fija, 1000),
                       levels = levels(datos_modelos$ednivel_cat)),
  religion_cat = factor(rep(religion_fija, 1000),
                        levels = levels(datos_modelos$religion_cat)),
  sexo_cat = factor(rep(c("Hombre", "Mujer"), each = 500),
                    levels = levels(datos_modelos$sexo_cat))
)

med.haz1 <- predict(loglog.1, newdata = nueva.haz, type = "link")
nueva.haz$med.haz1 <- med.haz1
nueva.haz$tiempo <- rep(tiempos, 2)

# h(t) = f(t) / S(t); dividir entre t convierte la densidad de log(t) a la de t.
nueva.haz$haz1 <- dlogis(log(nueva.haz$tiempo),
                         location = nueva.haz$med.haz1, scale = loglog.1$scale) /
  (nueva.haz$tiempo * plogis(log(nueva.haz$tiempo),
                             location = nueva.haz$med.haz1,
                             scale = loglog.1$scale, lower.tail = FALSE))

ggplot(data = nueva.haz, aes(x = tiempo, y = haz1, group = sexo_cat)) +
  geom_line(aes(color = sexo_cat)) +
  scale_color_manual(name = "Sexo", values = c("Hombre" = "purple", "Mujer" = "green")) +
  ggtitle("Curvas de hazard: modelo loglogístico") +
  xlab("Edad a la primera unión(años)") + ylab("Hazard(por año)")+
  theme_classic()
```



Las curvas de hazard estimadas con el modelo loglogístico para hombres y mujeres, manteniendo constantes la educación y la religión, presentan una forma similar a la observada en la pregunta 1, aumentan hasta alcanzar un máximo y luego disminuyen. Sin embargo, el descenso es más gradual y, en el rango de edades mostrado, no se aproximan tanto a cero como la curva suavizada. Por tanto, el modelo reproduce el patrón general, aunque difiere en la intensidad del descenso.

Pregunta 6

Tome todos los modelos paramétricos que estimó en el punto 2 con la función survreg. Compare los intervalos de confianza "teóricos" (generados con cofint) con los intervalos de confianza no paramétricos de bootstrap para todos los coeficientes de cada modelo, y argumente cuán parecidos son (20 ptos). Si la distribución paramétrica escogida no se puede estimar con bootstrap, tiene permiso de escoger otra distribución paramétrica.

```
set.seed(123)
```

Se comparan intervalos de confianza del 95% para todos los coeficientes de regresión, incluido el intercepto. Se utiliza bootstrap no paramétrico por remuestreo de individuos e intervalos percentiles. Siguiendo el laboratorio, ambas estimaciones se presentan en la escala exponenciada; no se interpretan como hazard ratios. El parámetro auxiliar de escala no forma parte de esta comparación de coeficientes de regresión.

Weibull

```
weib.1 = update(weib.1,
                formula = Surv(tiempo_union, evento) ~ ednivel_cat + religion_cat + sexo_cat,
                data = datos_modelos, model = TRUE)

weib.boot <- censboot_summary(weib.1, R = 999, pval_precision = 0.05)
```

```
Using exponentiated coefficients.
```

```
ic.weib <- cbind(exp(confint(weib.1)), weib.boot[, c(2, 3)])
colnames(ic.weib) <- c("Teórico inferior", "Teórico superior",
                       "Bootstrap inferior", "Bootstrap superior")
round(ic.weib, 3)
```

```
                          Teórico inferior Teórico superior
(Intercept)                         35.924           39.474
ednivel_catPrimaria o menos          0.861            0.951
ednivel_catSecundaria                0.878            0.974
religion_catNo creyente              0.852            0.978
religion_catOtra religión            0.874            0.954
sexo_catMujer                        0.843            0.909
                          Bootstrap inferior Bootstrap superior
(Intercept)                           35.652            40.011
ednivel_catPrimaria o menos            0.847             0.963
ednivel_catSecundaria                  0.866             0.983
religion_catNo creyente                0.838             1.001
religion_catOtra religión              0.857             0.974
sexo_catMujer                          0.826             0.927
```

Exponencial

```
exp.1 = update(exp.1,
               formula = Surv(tiempo_union, evento) ~ ednivel_cat + religion_cat + sexo_cat,
               data = datos_modelos, model = TRUE)

exp.boot <- censboot_summary(exp.1, R = 999, pval_precision = 0.05)
```

```
Using exponentiated coefficients.
```

```
ic.exp <- cbind(exp(confint(exp.1)), exp.boot[, c(2, 3)])
colnames(ic.exp) <- c("Teórico inferior", "Teórico superior",
                      "Bootstrap inferior", "Bootstrap superior")
round(ic.exp, 3)
```

```
                          Teórico inferior Teórico superior
(Intercept)                         45.809           58.517
ednivel_catPrimaria o menos          0.601            0.777
ednivel_catSecundaria                0.929            1.219
religion_catNo creyente              0.811            1.161
religion_catOtra religión            0.843            1.061
sexo_catMujer                        0.700            0.851
                          Bootstrap inferior Bootstrap superior
(Intercept)                           47.536            56.442
ednivel_catPrimaria o menos            0.625             0.749
ednivel_catSecundaria                  0.968             1.174
religion_catNo creyente                0.855             1.100
religion_catOtra religión              0.874             1.025
sexo_catMujer                          0.719             0.829
```

Gaussiana

```
gauss.1 = update(gauss.1,
                 formula = Surv(tiempo_union, evento) ~ ednivel_cat + religion_cat + sexo_cat,
                 data = datos_modelos, model = TRUE)

gauss.boot <- censboot_summary(gauss.1, R = 999, pval_precision = 0.05)
```

Using exponentiated coefficients.

```
ic.gauss <- cbind(exp(confint(gauss.1)), gauss.boot[, c(2, 3)])
colnames(ic.gauss) <- c("Teórico inferior", "Teórico superior",
                        "Bootstrap inferior", "Bootstrap superior")
round(ic.gauss, 3)
```

```
                           Teórico inferior Teórico superior
(Intercept)                    5.982167e+13     5.137981e+14
ednivel_catPrimaria o menos    5.000000e-03     4.700000e-02
ednivel_catSecundaria          3.700000e-02     3.790000e-01
religion_catNo creyente        3.700000e-02     8.290000e-01
religion_catOtra religión      9.100000e-02     7.000000e-01
sexo_catMujer                  8.000000e-03     4.600000e-02
                           Bootstrap inferior Bootstrap superior
(Intercept)                      5.858562e+13       5.595939e+14
ednivel_catPrimaria o menos      5.000000e-03       4.300000e-02
ednivel_catSecundaria            4.400000e-02       3.840000e-01
religion_catNo creyente          4.000000e-02       7.640000e-01
religion_catOtra religión        1.030000e-01       6.440000e-01
sexo_catMujer                    8.000000e-03       4.500000e-02
```

Lognormal

```
logn.1 = update(logn.1,
                formula = Surv(tiempo_union, evento) ~ ednivel_cat + religion_cat + sexo_cat,
                data = datos_modelos, model = TRUE)

logn.boot <- censboot_summary(logn.1, R = 999, pval_precision = 0.05)
```

Using exponentiated coefficients.

```
ic.logn <- cbind(exp(confint(logn.1)), logn.boot[, c(2, 3)])
colnames(ic.logn) <- c("Teórico inferior", "Teórico superior",
                       "Bootstrap inferior", "Bootstrap superior")
round(ic.logn, 3)
```

```
                           Teórico inferior Teórico superior
(Intercept)                          30.811           33.030
ednivel_catPrimaria o menos           0.805            0.867
ednivel_catSecundaria                 0.867            0.935
religion_catNo creyente               0.882            0.975
religion_catOtra religión             0.922            0.985
sexo_catMujer                         0.827            0.875
                           Bootstrap inferior Bootstrap superior
```

```
(Intercept)                          30.895            33.017
ednivel_catPrimaria o menos           0.806             0.865
ednivel_catSecundaria                 0.870             0.932
religion_catNo creyente               0.882             0.977
religion_catOtra religión             0.926             0.984
sexo_catMujer                         0.827             0.876
```

Logística

```
logist.1 = update(logist.1,
                  formula = Surv(tiempo_union, evento) ~ ednivel_cat + religion_cat + sexo_cat,
                  data = datos_modelos, model = TRUE)

logist.boot <- censboot_summary(logist.1, R = 999, pval_precision = 0.05)
```

```
Using exponentiated coefficients.
```

```
ic.logist <- cbind(exp(confint(logist.1)), logist.boot[, c(2, 3)])
colnames(ic.logist) <- c("Teórico inferior", "Teórico superior",
                         "Bootstrap inferior", "Bootstrap superior")
round(ic.logist, 3)
```

```
                          Teórico inferior Teórico superior
(Intercept)                   8.78331e+12       4.8319e+13
ednivel_catPrimaria o menos   4.00000e-03       2.5000e-02
ednivel_catSecundaria         3.40000e-02       2.1100e-01
religion_catNo creyente       7.10000e-02       8.1700e-01
religion_catOtra religión     1.84000e-01       8.9200e-01
sexo_catMujer                 1.00000e-02       3.7000e-02
                          Bootstrap inferior Bootstrap superior
(Intercept)                    8.587007e+12       5.296561e+13
ednivel_catPrimaria o menos    4.000000e-03       2.500000e-02
ednivel_catSecundaria          3.500000e-02       2.040000e-01
religion_catNo creyente        7.700000e-02       8.630000e-01
religion_catOtra religión      2.100000e-01       7.960000e-01
sexo_catMujer                  1.000000e-02       3.600000e-02
```

Loglogística

```
loglog.1 = update(loglog.1,
                  formula = Surv(tiempo_union, evento) ~ ednivel_cat + religion_cat + sexo_cat,
                  data = datos_modelos, model = TRUE)

loglog.boot <- censboot_summary(loglog.1, R = 999, pval_precision = 0.05)
```

```
Using exponentiated coefficients.
```

```
ic.loglog <- cbind(exp(confint(loglog.1)), loglog.boot[, c(2, 3)])
colnames(ic.loglog) <- c("Teórico inferior", "Teórico superior",
                         "Bootstrap inferior", "Bootstrap superior")
round(ic.loglog, 3)
```

```
                          Teórico inferior Teórico superior
```

```
(Intercept)                          29.790           31.731
ednivel_catPrimaria o menos           0.797            0.853
ednivel_catSecundaria                 0.864            0.925
religion_catNo creyente               0.891            0.978
religion_catOtra religión             0.934            0.992
sexo_catMujer                         0.822            0.866
                          Bootstrap inferior Bootstrap superior
(Intercept)                           29.818             31.812
ednivel_catPrimaria o menos            0.798              0.853
ednivel_catSecundaria                  0.867              0.924
religion_catNo creyente                0.892              0.983
religion_catOtra religión              0.936              0.992
sexo_catMujer                          0.823              0.866
```

Comparación

Con 999 réplicas y la semilla fijada, los intervalos teóricos y bootstrap presentan la siguiente comparación:

Modelo	Comparación de los intervalos
Weibull	Los intervalos bootstrap son más amplios. Para No creyente frente a Católica, el intervalo teórico exponenciado es aproximadamente [0.852, 0.978], mientras que el bootstrap es [0.838, 1.001]. Por tanto, el primero excluye el 1 y el segundo lo incluye apenas; la conclusión sobre ese coeficiente es sensible al método.
Exponencial	Los intervalos bootstrap son más estrechos, pero ambos métodos coinciden en cuáles coeficientes tienen intervalos que incluyen el 1.
Gaussiana	Los intervalos tienen diferencias de amplitud, pero mantienen conclusiones coincidentes respecto a la inclusión del 1. Los valores grandes del intercepto corresponden a su exponenciación, no a edades estimadas.
Lognormal	Los límites son muy cercanos y no cambia la conclusión sobre los coeficientes.
Logística	Los intervalos son similares, aunque para Otra religión el bootstrap es más estrecho. No cambia la conclusión respecto a la inclusión del 1.
Loglogística	Los límites son muy cercanos para todos los coeficientes, incluido el intercepto. Por ejemplo, para Mujer frente a Hombre son aproximadamente [0.822, 0.866] con el método teórico y [0.823, 0.866] con bootstrap.

En el modelo loglogístico seleccionado, ambos métodos producen resultados muy parecidos y los intervalos de todas las predictoras excluyen el 1.

Pregunta 7

Cuál es el mensaje central del artículo de Yashin y Vaupel (10 ptos.).

Vaupel y Yashin (1985) muestran que la heterogeneidad entre individuos y la selección de quienes permanecen en riesgo pueden producir curvas de hazard poblacionales muy distintas de las individuales. Quienes

tienen mayor riesgo tienden a experimentar el evento antes, por lo que cambia la composición del grupo que sigue sin experimentarlo. Así, un hazard poblacional decreciente no implica necesariamente que el riesgo de cada persona disminuya. La idea central es no atribuir automáticamente los patrones agregados a cambios individuales o a efectos de una intervención sin considerar esta selección.